

Deep Learning 3 (na 17.11.24)

1. *Uczenie CD (Contrastive Divergence).*

Zaimplementować samodzielnie (na podstawie wykładu) uczenie typu CD, pisząc procedury przejścia pomiędzy warstwą "wizualną" i ukrytą w sieci RBM. Zamodelować macierz W , wektory h i v oraz proces losowania. Sprawdzić na prostym przykładzie.

2. *Sieć RBM (Restricted Boltzmann Machine)*

Użyć mechanizmu CD do wyuczenia z danych reprezentacji ukrytej i wykorzystać tę reprezentację do przewidzenia wartości "wizualnej". Tego typu sieć RBM nadaje się do tworzenia rekomendacji tj. znajdowania powiązań np. typu użytkownik-produkt z wiedzy o częściowych wyborach różnych produktów przez różnych użytkowników. Użyć zbiorów dotyczących preferencji filmowych lub książkowych, itp.

3. *Sieć DBN (Deep Belief Network)*

Przedstawić dowolną, działającą sieć DBN w problemie klasyfikacji/regresji/inżynierii cech.

4. *Sieć AE (Autoencoder)*

Zbudować koder i dekoder (autokoder) własnych przykładów (ale nie obrazów). Celem treningu takiego układu jest dobra kompresja modelu, która daje wgląd w tzw. przestrzeń ukrytą cech (latent space). Zwizualizować grupy punktów należące do różnych klas w przestrzeni ukrytej.

5. *Autokoder obrazów*

Zbudować autokoder obrazów składający się z kodera ($N \times (\text{Conv2D} + \text{MaxPool})$) i dekodera ($N \times \text{Conv2DTranspose}$), gdzie w każdej z tych części dokonuje się stopniowa kompresja/dekompresja obrazu. W obu częściach sieci zbadać przydatność różnych funkcji aktywacji. Warstwa Keras Conv2DTranspose działa jak odwrotna konwolucja (nie w sensie matematycznym, tylko funkcjonalnym, tj. z "filtru" robi "obraz"). Przetestować dobroć hiperparametrów na zbiorze walidacyjnym.

6. *Sieć VAE (Variational Autoencoder)*

Zbudować sieć VAE i wygenerować dowolne obiekty z ciągłej przestrzeni ukrytej.